




#### **IA- Redes Neurias**

Rede Multi-Layer Perceptron (MLP)

#### Perceptron e Adaline




Prof. Myriam Delgado

# Perceptron e Adaline


Y∈ {0,1}

Aplicação em Problemas de Classificação Linearmente Separáveis




Prof. Myriam Delgado

# Perceptron e Adaline




Y∈ {-α, +α}
Aplicação em
Aproximação
De Funções
(combinação
Linear de
Funções não
Lineares)




Prof. Myriam Delgado

#### Perceptron Atual




Perceptron Atual: MLP de camada única (aceita diferentes funções de ativação)

#### Perceptron Atual



# RNAs: Perceptron (resolução de problemas)


XOR lógico: não linearmente separável Perceptron não resolve



<b>x1</b>	<b>x2</b>	У
0	0	0
0	1	1
1	0	1
1	1	0


# Perceptron → MLP para resolver XOR

Rede Neural (1 camada): partições independentes no espaço



# RNAs: MLP (resolução de problemas)

XOR lógico: Mais camadas combinando AND e OR




XOR	Lógico

<b>x1</b>	<b>x2</b>	Z1 AND	Z2 OR	Y
0	0	0	0	0
0	1	0	1	1
1	0	0	1	1
1	1	1	1	0

#### RNAs: MLP (resolução de problemas)

XOR lógico: PerceptronB + Mais uma camada


 $Y=x1 XOR x2 \leftrightarrow not (x1 AND x2) AND! (x1 OR x2)$ 



## RNAs: Neurônio MCP (resolução de problemas)


XOR lógico: não linearmente separável

Por que as redes multicamadas são capazes de resolver XOR ?




# Multi-Layer Perceptron


Treinamento (descida do gradiente)




## Neurônio na MLP: função de ativação Sigmoide



# Neurônio na MLP: partição x1 x x2





#### Neurônio na MLP:




Vimos o que acontece se alterarmos os pesos w1, w2 (w2 > w1)

$$\Theta = 0$$
, w1=1, w2=3







## Neurônio na MLP: Abstração na partição




Vimos o que acontece se alterarmos os pesos w1, w2 (w1 > w2)

$$\Theta = 0$$
, W1=3, w2=1







# Neurônio na MLP: Abstração na partição




Vimos o que acontece se alterarmos o limiar  $\Theta$ , e os pesos w1, w2

$$\Theta = 10$$
, W1=3, w2=1







## Neurônio na MLP: Abstração na partição



Vimos o que acontece se alterarmos o limiar Θ, e os Pesos w1, w2

$$\Theta = -10$$
, W1=3, w2=1







## Multi-Layer Perceptron

- o Arquitetura da rede
- o Modelo do neurônio: função de ativação
- Treinamento x Aplicação


# MLP: Treinamento e Classificação






# MLP: Treinamento e Classificação


# TREINAMENTO $\begin{array}{c} & & \\ & \\ & \\ & \\ \end{array}$ Classificação



# MLP: Treinamento e Classificação




## MLP: Treinamento e Regressão




O Treinamento de vários neurônios permite o ajuste dos parâmetros (pesos e bias) modelando diferentes saídas no nível hidden


#### MLP: Treinamento e Regressão



#### MLP: Treinamento e Regressao->Classificação




# MLP: Treinamento e Aplicação




2 entradas 1 saída como no exemplo ao lado

Entendendo a interação entre as camadas

## Multi-Layer Perceptron tradicional




# MLP híbrida para aproximação de funções




# MLP híbrida: Tg Hiperbólica (N<sub>h</sub>)

f = Tangente Hiperbólica (hidden)




# MLP híbrida: Linear(N<sub>s</sub>)

f = função Linear (saída)



# MLP Híbrida (Perceptron + Adaline)




# Aprendizado Conexionista (MLP híbrida)

O papel dos pesos

# Aprendizado Conexionista (MLP híbrida)


O papel dos pesos



$$y = c_0 + c_1 g(b_1 x + a_1) + c_2 g(b_2 x + a_2)$$
:

Exemplo: Forma "construtiva" de aproximação de um mapeamento não-linear

Exemplo: Forma "construtiva" de aproximação de um mapeamento não-linear




$$f(\mathbf{w}) = \underbrace{c_1 g(b_1 x + a_1)}_{a} + \underbrace{c_2 g(b_2 x + a_2)}_{b} + \underbrace{c_3 g(b_3 x + a_3)}_{c} + \underbrace{c_4 g(b_4 x + a_4)}_{d} + \underbrace{c_5 g(b_5 x + a_5)}_{e} + \underbrace{c_0}_{bias}$$

$$f(\mathbf{w}) = \underbrace{c_1 g(b_1 x + a_1)}_{a} + \underbrace{c_2 g(b_2 x + a_2)}_{b} +$$


$$+\underbrace{c_5g(b_5x+a_5)}_{e}$$

$$+\underbrace{c_3g(b_3x+a_3)}_{c}$$


$$+\underbrace{c_4g(b_4x+a_4)}_{\widetilde{d}}$$



# MLP Híbrida (Perceptron + Adaline)



## MLP Híbrida (Perceptron + Adaline)



Aproximação de Funções